Hoe kan een computer handgebaren voor letters herkennen? Fotobewerking, meer voorbeelden en uitleg over de handvorm

TODO: drie namen en studentnummers [1]

Samenvatting

Kan een computer op een foto zien welke letter iemand met de hand uitbeeldt? Wij onderzoeken drie mogelijke verbeteringen: foto's vooraf bewerken, het programma meer voorbeelden geven en de handvorm duidelijker beschrijven. Voor de eerste twee onderdelen moeten de resultaten nog worden toegevoegd. Het derde onderdeel vergelijkt acht combinaties van handbeschrijvingen op 60.251 foto's. Extra beschrijvingen, zoals "de middelvinger is gebogen", helpen niet steeds. Een kleine verbetering blijkt bovendien samen te hangen met de gebruikte handpunten. We weten nog niet of deze aanpak bij nieuwe mensen of met een gewone webcam beter werkt.

1. Wat willen we onderzoeken?

In het handalfabet van de Amerikaanse Gebarentaal (ASL) worden letters met de hand uitgebeeld. Wij onderzoeken losse foto's van de letters A tot en met Z. We onderzoeken daarmee geen gesprekken of de bewegingen die bij J en Z horen.

Onze hoofdvraag is: *Wat helpt een computer om de hand op een foto te vinden en de uitgebeelde letter goed te herkennen?* We verdelen dit in drie vragen:

1. **RQ1 – Foto's bewerken:** Vindt het programma vaker een hand als we de foto eerst bewerken? En liggen de gevonden punten dan ook op de juiste plek?

2. **RQ2 – Meer voorbeelden:** Herkent het programma letters beter als het met meer verschillende foto's oefent?

3. **RQ3 – Handvorm beschrijven:** Helpen eigen handkenmerken en gewrichtshoeken, en kunnen ze de richtingsbeschrijving van Shin vervangen?

[1] Open Universiteit.

Nederlandse werkversie van een gezamenlijk studieproject.

We testen deze mogelijkheden apart. Als een bewerkte foto meer handpunten oplevert, weten we bijvoorbeeld nog niet of het programma daardoor ook de juiste letter kiest.

2. Hoe werkt de herkenning?

Het programma begint met het zoeken naar de hand. MediaPipe, bestaande software voor beeldherkenning, schat 21 punten bij onder meer de pols, knokkels en vingertoppen (Zhang et al., 2020). Je kunt deze punten zien als stippen op een eenvoudig handskelet. Als een stip verkeerd ligt, kan ook de beschrijving van de hand verkeerd worden.

Daarna beschrijven we de hand met afstanden en richtingen tussen de stippen. Deze basisaanpak komt van Shin et al. (2021). Een leerprogramma oefent met zulke beschrijvingen en de bijbehorende letters. Vervolgens testen we of het de letter kiest op foto's waarmee het niet heeft geoefend.

Wij gebruiken twee bestaande leermethoden, SVM en LightGBM (Ke et al., 2017). Hun namen zijn vooral nodig om de proeven te kunnen herhalen. De instellingen staan in bijlage A.

TODO [PREP/SIZE]: Voeg bronnen toe die de gekozen fotobewerkingen en de proef met meer voorbeelden onderbouwen.

3. Hoe testen we dit?

3.1. Oefenen en toetsen gescheiden houden

We gebruiken een bestaande verzameling van 78.000 foto's, de Kaggle ASL Alphabet-set. Bij 60.251 foto's accepteerde het programma precies één gevonden hand. Alleen die foto's zijn gebruikt voor de uitgewerkte proef met handbeschrijvingen. De resultaten daarvan vertellen dus niet hoe goed het hele programma op alle foto's werkt.

We verdelen de foto's voor deze proef in vijf groepen. Het programma oefent met vier groepen en wordt getoetst op de overgebleven groep. We herhalen dit totdat iedere groep aan de beurt is geweest. De verschillende aanpakken krijgen dezelfde toetsfoto's. Een bewerkte kopie mag niet bij de toets staan als het origineel bij het oefenen hoort.

Voor de beoordeling tellen we eerst hoeveel letters goed zijn herkend. Daarnaast kijken we naar *precisie*: als het programma tien keer H zegt en acht keer gelijk heeft, is de precisie voor H 80%. Maar het kan daarnaast echte H's missen. De *F1-score* houdt met beide soorten fouten rekening en ligt tussen 0 en 1; een hogere score is beter. Bij macro-precisie en macro-F1 telt iedere letter even zwaar mee. De technische afspraken staan in bijlage A.

TODO [TEAM]: Controleer dat de drie bijdragen dezelfde foto's en afspraken gebruiken, of leg de verschillen uit.

3.2. RQ1: De foto's vooraf bewerken

Als het programma geen hand vindt, proberen we het nog eens met een bewerkte versie van dezelfde foto. De medestudent onderzoekt verschillende bewerkingen. Daarna moet worden nagekeken of de gevonden punten werkelijk bij de hand passen. De voorgestelde bewerkingen staan in bijlage A.

TODO [PREP]: Vul in welke bewerkingen worden getest en hoe wordt gecontroleerd of de gevonden handpunten bruikbaar zijn.

3.3. RQ2: Met meer foto's oefenen

De tweede medestudent laat het programma met steeds meer verschillende foto's oefenen. De toetsfoto's blijven hetzelfde. Anders kan een hogere score ook komen doordat de toets gemakkelijker is geworden. Een bewerkte kopie telt niet als een nieuwe oorspronkelijke foto.

TODO [SIZE]: Vul in met hoeveel foto's wordt geoefend en hoe vaak de vergelijking wordt herhaald.

3.4. RQ3: Acht combinaties van handbeschrijvingen

We beschrijven de hand op vier manieren: afstanden, richtingen tussen handpunten, eigen categorieën zoals "vinger gebogen" en gemeten gewrichtshoeken. Afstanden blijven steeds aanwezig. De andere drie onderdelen zetten we aan of uit: dat geeft acht combinaties. Beide leermethoden krijgen dezelfde combinaties en toetsfoto's. De meetregels en controletool staan in bijlage C.

De gewrichtshoeken en categorieën komen uit geschatte 3D-wereldpunten. Shin gebruikt beeldhandpunten. Een bestaande controle berekent daarom ook gewrichtshoeken uit precies dezelfde punten als Shin. Zo onderscheiden we een andere beschrijving van een andere coördinatenbron (bijlage A–B).

Na het trainen onderzoeken we welke informatie een model gebruikt. We husselen één kenmerk of groep kenmerken tussen toetsfoto's en meten hoeveel precisie en F1 verloren gaan (permutatietest; scikit-learn developers, n.d.). De juiste letters blijven staan; het model wordt niet opnieuw getraind. Deze husseltests gebruiken 13.000 vaste toetsbeelden. De gewone vergelijking van de acht combinaties gebruikt alle 60.251 beelden.

4. Resultaten

4.1. RQ1: Vindt het programma meer handen?

TODO [PREP]: Voeg een figuur toe met aantallen extra gevonden handen en de beoordeling daarvan.

4.2. RQ2: Helpen meer oefenfoto's?

TODO [SIZE]: Voeg een grafiek toe met het aantal oefenfoto's en de herkenningsscores. Laat ook zien of herhaalde proeven ongeveer dezelfde uitkomst geven.

4.3. RQ3: Welke combinatie werkt beter?

Tabel 1 vergelijkt de acht combinaties. Alle scores gelden voor foto's waarin een hand gevonden is. "Wereldgewrichtshoeken" zijn metingen aan de geschatte 3D-hand; "eigen categorieën" zijn de beschrijvingen uit onze controletool.

Met Shin als basis geven de eigen categorieën bij SVM 22 minder correcte voorspellingen. Wereldgewrichtshoeken geven er 67 meer; beide toevoegingen samen 3 minder. Bij LightGBM verandert F1 door alleen de eigen categorieën van 0,9678 naar 0,9676. Zonder de richtingen geven categorieën en wereldhoeken samen 318 meer correcte voorspellingen dan alleen afstanden. De precieze scores, paarsgewijze verschillen en controle met hoeken uit dezelfde punten staan in bijlage B. De bestaande controle met gewrichtshoeken uit dezelfde punten als Shin levert bij SVM slechts vier extra correcte voorspellingen op. De grotere winst met wereldpunten kan dus niet aan de hoekformule alleen worden toegeschreven.

4.4. Welke kenmerken gebruikt het model?

Bij SVM met Shin en eigen categorieën geeft het husselen van de buiging van de duim de grootste gemiddelde F1-daling (0,08 procentpunt). Bij LightGBM is dat de spreiding tussen middel- en ringvinger (0,03 procentpunt). Dit laat zien welke informatie deze modellen gebruiken. Een kleine daling bewijst niet dat een kenmerk nutteloos is: andere kenmerken kunnen dezelfde informatie leveren. De detailresultaten staan in bijlage B. Een kenmerk dat een model gebruikt, hoeft als toevoeging nog geen betere classificatie op te leveren; belangrijkheid is modelafhankelijk (Fisher et al., 2019).

Tabel 1. De acht combinaties op dezelfde 60.251 toetsbeelden. Alle varianten bevatten afstanden. P is macro-precisie in procenten; F1 is macro-F1. Ieder beeld wordt uitsluitend voorspeld door een model dat zonder dat beeld is getraind.

	SVM		LightGBM	
Beschrijving van de hand	P (%)	F1	P (%)	F1
Basis: afstanden en richtingen	97,39	0,9739	96,80	0,9678
Alleen afstanden	94,43	0,9438	93,63	0,9355
Basis + eigen categorieën	97,36	0,9735	96,78	0,9676
Afstanden + eigen categorieën	94,64	0,9460	93,72	0,9364
Basis + wereldgewrichtshoeken	97,54	0,9752	96,71	0,9669
Afstanden + wereldgewrichtshoeken	95,05	0,9501	93,83	0,9377
Basis + categorieën + wereldhoeken	97,39	0,9738	96,78	0,9675
Afstanden + categorieën + wereldhoeken	94,97	0,9493	93,87	0,9379

4.5. Extra proeven met handoriëntatie

We hebben ook oefenfoto's gespiegeld om het programma met links/rechts-variatie te laten oefenen. Dat helpt sterk op onze kunstmatig gespiegelde toetsfoto's, maar kost op de oorspronkelijke foto's 26 goede voorspellingen. Dit is nog geen bewijs dat het ook bij echte linkshandige gebruikers beter werkt (bijlage D).

Een andere aanpak spiegelt links gedetecteerde handen vóór oefenen en toetsen naar dezelfde stand. We vergelijken alleen oorspronkelijke foto's met gevonden handpunten. Voor het SVM-model met extra gewrichtsmetingen daalt de precisie van 97,54% naar 97,32% en F1 van 0,9752 naar 0,9732: 136 minder goede voorspellingen. Op het aparte mengsel van oorspronkelijke en gespiegelde beelden helpt normaliseren wel, maar spiegeltraining blijft beter (bijlage F).

Bij G en H is de palm gewoonlijk naar de gebaarder of opzij gericht (Shield et al., 2022; Vicars, n.d.). De bekeken trainingsfoto's uit de Kaggle-set die Shin gebruikte tonen juist de palm. Daarom voegen we naast de oorspronkelijke G/H-trainingsbeschrijvingen een halve draai om de verticale as toe.

Op ongewijzigde toetsfoto's herstellen we vier fouten en maken vijf nieuwe. Dat meet behoud op de dataset; palmgerichte G/H herkennen is niet ons gebruiksdoel. Een juiste datasetletter betekent niet vanzelf een juiste ASL-uitvoering.

Als we ook de G/H-toetslandmarks draaien, stijgt macro-F1 door rotatietraining van 0.8693 naar 0.9757. De tweede vorm wordt dus geleerd. Echte handrugbeelden kunnen echter andere punten opleveren door verborgen vingers. Een aanvullende proef met verstoorde punten geeft hier geen extra winst. De eenvoudige nagebootste handbeelden worden door MediaPipe niet geaccepteerd (bijlage E).

In vier vrij gekozen webcamvoorbeelden blijft de rotatievariant twee G's met zichtbare handrug als H herkennen; een H wordt wel hersteld. De geschatte handvorm verschilt van een zuiver gedraaid trainingsskelet (bijlage E). Dit is foutanalyse, geen nieuwe nauwkeurigheidsmeting.

5. Discussie en voorlopige conclusie

De eigen categorieën leveren hier geen overtuigende extra herkenningswinst bovenop Shin. In de geteste combinaties vervangen categorieën en gewrichtshoeken de richtingen ook niet volledig. De kleine wereldgewrichtswinst bij SVM keert niet terug bij LightGBM; bovendien speelt de coördinatenbron een rol. De trainingsvergelijkingen meten het effect van toevoegen of weglaten. De husseltests meten de afhankelijkheid van een eenmaal getraind model, waarbij samenhangende kenmerken elkaar kunnen vervangen.

Handen vóór het leren en toetsen naar dezelfde stand spiegelen maakt de herkenning minder gevoelig voor kunstmatig gespiegelde beelden. Op oorspronkelijke foto's met gevonden handpunten verbetert dit de resultaten niet. Trainen met oorspronkelijke én gespiegelde foto's werkt op het gemengde toetsbestand beter. Voor een conclusie over nieuwe linkshandige gebruikers zijn nog onafhankelijke opnamen nodig.

De rotatie helpt op kunstmatig gedraaide G/H-punten. De oorspronkelijke toets meet behoud op het oude aanzicht. De nieuwe praktijkvoorbeelden laten zien dat G met zichtbare handrug nog als H wordt herkend. De hoge kunstmatige score draagt dus niet vanzelf over naar de live-camera. Rotatietraining is daarmee nog geen aangetoonde oplossing voor deze live-verwarring; de vier vrij gekozen beelden bepalen niet hoe vaak dit probleem voorkomt.

De resultaten zijn nog geen eindtest. Tijdens de ontwikkeling is vaker naar dezelfde toetsgroepen gekeken; dat kan een te gunstig beeld geven (Cawley & Talbot, 2010). Bovendien weten we niet of de groepen echt verschillende mensen bevatten. Een goede score op deze foto's betekent dus niet vanzelf dat de webcam bij een nieuw persoon even goed werkt. Onze resultaten zijn ook niet rechtstreeks vergelijkbaar met die van Shin, omdat de selectie en verdeling van de foto's verschillen.

Voor de gezamenlijke conclusie ontbreken nog twee bijdragen: vinden we door fotobewerking vaker bruikbare handpunten, en helpt oefenen met meer foto's? Een extra gevonden hand is pas bruikbaar als de punten goed liggen. En meer foto's helpen alleen aantoonbaar als we steeds met dezelfde toetsfoto's vergelijken.

TODO [TEAM]: Voeg de antwoorden op RQ1/RQ2 toe en beschrijf daarna wat de drie onderzoeken samen laten zien.

Tekst en software zijn mede met AI opgesteld; de auteurs blijven verantwoordelijk voor de inhoud. Webcamopnamen vereisen instemming en blijven lokaal.

Referenties

Cawley, G. C. and Talbot, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11 (70):2079–2107, 2010. URL https://jmlr.org/papers/v11/cawley10a.html.

Fisher, A., Rudin, C., and Dominici, F. All models are wrong, but many are useful: Learning a variable's importance by studying an entire class of prediction models simultaneously. *Journal of Machine Learning Research*, 20(177):1–81, 2019. URL https://jmlr.org/papers/v20/18-760.html.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

scikit-learn developers. Permutation feature importance. scikit-learn documentation, n.d. URL https://scikit-learn.org/stable/modules/permutation_importance.html. Accessed 7 November 2026.

Shield, A., Igel, M., and Meier, R. P. Are palm reversals the pronoun reversals of sign language? evidence from a fingerspelling task. *Frontiers in Psychology*, 13: 953019, 2022. doi: 10.3389/fpsyg.2022.953019. URL https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2022.953019/full.

Shin, J., Matsuoka, A., Hasan, M. A. M., and Srizon, A. Y. American sign language alphabet recognition by extracting feature from hand pose estimation. *Sensors*, 21(17):5856, 2021. doi: 10.3390/s21175856. URL https://pmc.ncbi.nlm.nih.gov/articles/PMC8434249/.

Vicars, W. ASL feedback: fingerspelled G and H. ASL University / Lifeprint, n.d. URL https://www.lifeprint.com/asl101/topics/feedback.htm. Accessed 7 November 2026.

Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., and Grundmann, M. MediaPipe Hands: On-device real-time hand tracking. *arXiv preprint arXiv:2006.10214*, 2020. URL https://arxiv.org/abs/2006.10214.