Hoe kan een computer handgebaren voor letters herkennen? Fotobewerking, meer voorbeelden en uitleg over de handvorm

TODO: drie namen en studentnummers [1]

Samenvatting

Kan een computer op een foto zien welke letter iemand met de hand uitbeeldt? Wij onderzoeken drie mogelijke verbeteringen: foto's vooraf bewerken, het programma meer voorbeelden geven en de handvorm duidelijker beschrijven. Voor de eerste twee onderdelen moeten de resultaten nog worden toegevoegd. Het derde onderdeel is getest op 60.251 foto's. Extra beschrijvingen, zoals "de middelvinger is gebogen", helpen niet steeds. Een kleine verbetering blijkt bovendien samen te hangen met de gebruikte handpunten. We weten nog niet of deze aanpak bij nieuwe mensen of met een gewone webcam beter werkt.

1. Wat willen we onderzoeken?

In het handalfabet van de Amerikaanse Gebarentaal (ASL) worden letters met de hand uitgebeeld. Wij onderzoeken losse foto's van de letters A tot en met Z. We onderzoeken daarmee geen gesprekken of de bewegingen die bij J en Z horen.

Onze hoofdvraag is: *Wat helpt een computer om de hand op een foto te vinden en de uitgebeelde letter goed te herkennen?* We verdelen dit in drie vragen:

1. **RQ1 – Foto's bewerken:** Vindt het programma vaker een hand als we de foto eerst bewerken? En liggen de gevonden punten dan ook op de juiste plek?
2. **RQ2 – Meer voorbeelden:** Herkent het programma letters beter als het met meer verschillende foto's oefent?
3. **RQ3 – Handvorm beschrijven:** Helpt extra uitleg, zoals welke vingers gebogen of gespreid zijn?

We testen deze mogelijkheden apart. Als een bewerkte foto meer handpunten oplevert, weten we bijvoorbeeld nog niet of het programma daardoor ook de juiste letter kiest.

[1]Open Universiteit.

Nederlandse werkversie van een gezamenlijk studieproject.

2. Hoe werkt de herkenning?

Het programma begint met het zoeken naar de hand. MediaPipe, bestaande software voor beeldherkenning, schat 21 punten bij onder meer de pols, knokkels en vingertoppen (Zhang et al., 2020). Je kunt deze punten zien als stippen op een eenvoudig handskelet. Als een stip verkeerd ligt, kan ook de beschrijving van de hand verkeerd worden.

Daarna beschrijven we de hand met afstanden en richtingen tussen de stippen. Deze basisaanpak komt van Shin et al. (2021). Een leerprogramma oefent met zulke beschrijvingen en de bijbehorende letters. Vervolgens testen we of het de letter kiest op foto's waarmee het niet heeft geoefend.

Wij gebruiken twee bestaande leermethoden, SVM en LightGBM (Ke et al., 2017). Hun namen zijn vooral nodig om de proeven te kunnen herhalen. De instellingen staan in bijlage A.

TODO [PREP/SIZE]: Voeg bronnen toe die de gekozen fotobewerkingen en de proef met meer voorbeelden onderbouwen.

3. Hoe testen we dit?

3.1. Oefenen en toetsen gescheiden houden

We gebruiken een bestaande verzameling van 78.000 foto's, de Kaggle ASL Alphabet-set. Bij 60.251 foto's accepteerde het programma precies één gevonden hand. Alleen die foto's zijn gebruikt voor de uitgewerkte proef met handbeschrijvingen. De resultaten daarvan vertellen dus niet hoe goed het hele programma op alle foto's werkt.

We verdelen de foto's voor deze proef in vijf groepen. Het programma oefent met vier groepen en wordt getoetst op de overgebleven groep. We herhalen dit totdat iedere groep aan de beurt is geweest. De verschillende aanpakken krijgen dezelfde toetsfoto's. Een bewerkte kopie mag niet bij de toets staan als het origineel bij het oefenen hoort.

Voor de beoordeling tellen we eerst hoeveel letters goed zijn herkend. Daarnaast kijken we naar *precisie*: als het programma tien keer H zegt en acht keer gelijk heeft, is de precisie voor H 80%. Maar het kan daarnaast echte H's missen. De *F1-score* houdt met beide soorten fouten rekening

en ligt tussen 0 en 1; een hogere score is beter. Bij macro-precisie en macro-F1 telt iedere letter even zwaar mee. De technische afspraken staan in bijlage A.

TODO [TEAM]: Controleer dat de drie bijdragen dezelfde foto's en afspraken gebruiken, of leg de verschillen uit.

3.2. RQ1: De foto's vooraf bewerken

Als het programma geen hand vindt, proberen we het nog eens met een bewerkte versie van dezelfde foto. De medestudent onderzoekt verschillende bewerkingen. Daarna moet worden nagekeken of de gevonden punten werkelijk bij de hand passen. De voorgestelde bewerkingen staan in bijlage A.

TODO [PREP]: Vul in welke bewerkingen worden getest en hoe wordt gecontroleerd of de gevonden handpunten bruikbaar zijn.

3.3. RQ2: Met meer foto's oefenen

De tweede medestudent laat het programma met steeds meer verschillende foto's oefenen. De toetsfoto's blijven hetzelfde. Anders kan een hogere score ook komen doordat de toets gemakkelijker is geworden. Een bewerkte kopie telt niet als een nieuwe oorspronkelijke foto.

TODO [SIZE]: Vul in met hoeveel foto's wordt geoefend en hoe vaak de vergelijking wordt herhaald.

3.4. RQ3: Meer uitleg over de handvorm

We voegen beschrijvingen toe zoals "vinger gebogen", "vingers uit elkaar" en "duim raakt wijsvinger". Ook meten we hoe ver gewrichten gebogen zijn. Zo onderzoeken we of duidelijk benoemde eigenschappen het leren gemakkelijker maken. De meetregels en plek voor een toolfoto staan in bijlage C.

De basisaanpak bevat al informatie over de handvorm. Het is dus mogelijk dat de extra beschrijvingen weinig nieuws toevoegen. Om dit te controleren, berekenen we gewrichtshoeken zowel met een aparte schatting van de hand in drie dimensies (3D) als met precies dezelfde punten die de basisaanpak gebruikt.

Tabel 1. Goed herkende foto's bij dezelfde toetsing. Iedere aanpak wordt op alle 60.251 foto's getoetst, zonder die toetsfoto's voor het oefenen te gebruiken.

Beschrijving van de hand	Aantal goed
Afstanden en richtingen: de basis	58.827
Basis met alle extra beschrijvingen	58.822
Basis met hoeken uit andere 3D-punten	58.894
Basis met hoeken uit dezelfde punten	58.831

4. Resultaten

4.1. RQ1: Vindt het programma meer handen?

TODO [PREP]: Voeg een figuur toe met aantallen extra gevonden handen en de beoordeling daarvan.

4.2. RQ2: Helpen meer oefenfoto's?

TODO [SIZE]: Voeg een grafiek toe met het aantal oefenfoto's en de herkenningsscores. Laat ook zien of herhaalde proeven ongeveer dezelfde uitkomst geven.

4.3. RQ3: Extra beschrijvingen helpen weinig

Tabel 1 laat zien hoeveel foto's goed worden herkend met SVM. De basisaanpak herkent bijna 98 van de 100 letters goed op de foto's waarin een hand gevonden is. Het volledige pakket extra beschrijvingen levert vijf correcte voorspellingen minder op. Bij de andere leermethode, LightGBM, helpt dit pakket een beetje, maar blijven de resultaten lager dan bij de SVM-basisaanpak.

De hoeken uit de andere 3D-schatting leveren 67 extra correcte voorspellingen op. Er worden daarbij 143 oude fouten hersteld, maar ook 76 nieuwe gemaakt. Met hoeken uit dezelfde handpunten als de basisaanpak blijven slechts vier extra correcte voorspellingen over. We kunnen de winst dus niet alleen verklaren doordat het programma extra uitleg over buiging krijgt. De precieze scores en de verschillen per letter staan in bijlage B.

4.4. Extra proeven: spiegelen en G/H draaien

We hebben ook oefenfoto's gespiegeld om het programma met links/rechts-variatie te laten oefenen. Dat helpt sterk op onze kunstmatig gespiegelde toetsfoto's, maar kost op de oorspronkelijke foto's 26 goede voorspellingen. Dit is nog geen bewijs dat het ook bij echte linkshandige gebruikers beter werkt (bijlage D).

In een aparte proef draaien we de beschrijving van G/H-handen een halve slag om de verticale as. Dat moet het andere aanzicht van de hand nabootsen. De proef herstelt vier fouten en maakt vijf nieuwe: vrijwel geen verschil. Een echte draaiing kan vingers verbergen; alleen handpunten draaien bootst dat niet na (bijlage E).

5. Discussie en voorlopige conclusie

Extra uitleg over de handvorm maakt de herkenning in deze proeven niet steeds beter. De basisaanpak bevat al veel van die informatie. De kleine verbetering met andere 3D-punten vraagt daarom om een voorzichtige uitleg.

De resultaten zijn nog geen eindtest. Tijdens de ontwikkeling is vaker naar dezelfde toetsgroepen gekeken; dat kan een te gunstig beeld geven (Cawley & Talbot, 2010). Bovendien weten we niet of de groepen echt verschillende mensen bevatten. Een goede score op deze foto's betekent dus niet vanzelf dat de webcam bij een nieuw persoon even goed werkt. Onze resultaten zijn ook niet rechtstreeks vergelijkbaar met die van Shin, omdat de selectie en verdeling van de foto's verschillen.

Voor de gezamenlijke conclusie ontbreken nog twee bijdragen: vinden we door fotobewerking vaker bruikbare handpunten, en helpt oefenen met meer foto's? Een extra gevonden hand is pas bruikbaar als de punten goed liggen. En meer foto's helpen alleen aantoonbaar als we steeds met dezelfde toetsfoto's vergelijken.

TODO [TEAM]: Voeg de antwoorden op RQ1/RQ2 toe en beschrijf daarna wat de drie onderzoeken samen laten zien.

Tekst en software zijn mede met AI opgesteld; de auteurs blijven verantwoordelijk voor de inhoud. Webcamopnamen vereisen instemming en blijven lokaal.

Referenties

Cawley, G. C. and Talbot, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11 (70):2079–2107, 2010. URL https://jmlr.org/papers/v11/cawley10a.html.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

Shin, J., Matsuoka, A., Hasan, M. A. M., and Srizon, A. Y. American sign language alphabet recognition by extracting feature from hand pose estimation. *Sensors*, 21(17):5856, 2021. doi: 10.3390/s21175856. URL https://pmc.ncbi.nlm.nih.gov/articles/PMC8434249/.

Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., and Grundmann, M. MediaPipe Hands: On-device real-time hand tracking. *arXiv preprint arXiv:2006.10214*, 2020. URL https://arxiv.org/abs/2006.10214.